

O prompt "melhor" não existe sem benchmark

Quando você compara estratégia e modelo ao mesmo tempo, prompt engineering deixa de ser opinião. O artigo mostra como medir ganho real antes de subir custo ou escalar stack.

- Leitura completa no artigo + notebook + CSVs no repositório

ARTIGO 0005 · PROMPT ENGINEERING AVANÇADO

Score Total por Estratégia e por Modelo

Laboratório multi-modelo: medindo o impacto das estratégias de prompt em modelos open-source



Pathbit Academy AI · Engenharia de IA para Produção

INSIGHTS Leitura Executiva

Qwen 0.5B responde a contratos
Subiu de 0.411 para 0.741 (+80.2% de ganho). Exemplos few-shot ancoraram estrutura e prioridade sem perda de semântica.

FLAN-T5 prefere checklists
Obteve 0.460 com checklist (+72.6% vs base), mas falhou em seguir contratos JSON/chaves estritas devido ao teto do modelo seq2seq.

Princípio de Engenharia
O ganho não pertence apenas ao prompt nem apenas ao modelo: ele emerge da compatibilidade entre o desenho de instrução e a capacidade da arquitetura.

Figura 4: A matriz comparativa revela como cada arquitetura extrai valor de diferentes técnicas de prompt

Benchmark comparando a matriz completa de estratégia e modelo.

O PROBLEMA OPERACIONAL

Resposta plausível ainda pode quebrar a operação

Prompt genérico costuma convencer na leitura rápida. Quando a saída precisa virar interface de sistema, ele falha justamente onde o time depende de previsibilidade: resumo estável, prioridade confiável e próxima ação objetiva.

Entender a mensagem não basta.
A saída precisa funcionar como interface.

O Erro que Quebra a Confiança

Instrução vaga vs. Contrato de saída estruturado em operações com LLM

INSTÁVEL

Sem Método (Instrução Vaga)

Quando o formato de resposta fica implícito, o modelo varia arbitrariamente o tom e a estrutura.

prompt_vago.txt

"Resuma o chamado: Cliente irritado com atraso na entrega."

SAÍDAS IMPREVISÍVEIS EM PRODUÇÃO:

1. Texto Prolixo sem Foco

"O cliente expressou descontentamento com a data prevista do frete e solicita resolução com certa prioridade..."

2. Bullet Points Aleatórios

- Motivo: pedido atrasado
- Urgência: alta
- Observação: verificar se tem estoque.

3. Desculpas do Modelo

"Como um modelo de inteligência artificial, sinto muito pelo transtorno do usuário..."

✗ Inviável para ingestão por APIs, bancos de dados ou gatilhos automatizados

DETERMINÍSTICO

Com Método (Contrato de Saída)

O contrato especifica campos obrigatórios, vocabulário fechado e formato padronizado.

prompt_estruturado.txt

"Você é analista de atendimento Pathbit.
Responda EXATAMENTE com 3 linhas:
resumo: <uma frase>
prioridade: <alta|media|baixa>
proxima_acao: <uma frase objetiva>
Mensagem: Cliente irritado com atraso na entrega."

SAÍDA 100% VALIDÁVEL & INTEGRÁVEL:

resposta_validada.json

{
 "resumo": "Cliente reclama de atraso fora do prazo contratual",
 "prioridade": "ALTA",
 "proxima_acao": "Abrir ticket técnico N2 e acionar transportadora em 1h"
}

✓ Validação instantânea via Regex / Pydantic • Roteamento automatizado sem intervenção manual

Resposta plausível ainda pode quebrar a operação quando não existe contrato de saída.

O laboratório separa estratégia de capacidade do modelo

O runner cruza `Qwen/Qwen2.5-0.5B-Instruct` e `google/flan-t5-small` com quatro estratégias: `base`, `estruturado`, `few_shot` e `checklist`.

Isso permite responder de onde veio o ganho: do contrato de saída, do exemplo orientador, do checklist operacional ou do teto do próprio modelo.



O PRIMEIRO SALTO REAL

Contrato de saída continua sendo o divisor de águas

O primeiro avanço não é escrever um prompt mais bonito. É exigir formato estável, com campos nomeados e estrutura mínima validável para o restante do sistema.

Linguagem natural vira interface de sistema quando o formato deixa de ser implícito.



Benchmark bom mede forma e significado ao mesmo tempo

O score final combina estrutura, keywords obrigatórias, acerto de prioridade e similaridade semântica. Isso evita duas ilusões comuns: texto bonito sem utilidade operacional, ou formato rígido com resposta semanticamente fraca.

Score Total por Estratégia e por Modelo

Laboratório multi-modelo: medindo o impacto das estratégias de prompt em modelos open-source



A matriz inteira roda no mesmo dataset e é julgada pelos mesmos critérios.

INSIGHTS

Leitura Executiva

Qwen 0.5B responde a contratos

Subiu de 0.411 para 0.741 (+80.2% de ganho). Exemplos few-shot ancoraram estrutura e prioridade sem perda de semântica.

FLAN-T5 prefere checklists

Obteve 0.460 com checklist (+72.6% vs base), mas falhou em seguir contratos JSON/chaves estritas devido ao teto do modelo seq2seq.

Princípio de Engenharia

O ganho não pertence apenas ao prompt nem apenas ao modelo: ele emerge da compatibilidade entre o desenho de instrução e a capacidade da arquitetura.

RESULTADO OBSERVADO

O ganho muda com o modelo, não só com o prompt

Qwen: `few_shot` 0.741 vs `base` 0.408, ganho relativo de +81.7% no score composto.
FLAN: `checklist` 0.460 vs `base` 0.266, ganho de +72.6%.

A leitura correta é simples: o mesmo prompt não rende igual em todo modelo.

Estratégia e modelo: score não é acurácia

Fonte: benchmark_resumo.csv. Recorte pequeno; compare estrutura, prioridade e semântica.

Resumo medido

modelo_geracao	estrategia	score_estrutura	score_prioridade	score_total
Qwen/Qwen2.5-0.5B-Instruct	few_shot	0.667	0.500	0.741
Qwen/Qwen2.5-0.5B-Instruct	estruturado	0.667	0.500	0.732
Qwen/Qwen2.5-0.5B-Instruct	checklist	1.000	1.000	0.605
google/flan-t5-small	checklist	0.000	0.000	0.460
Qwen/Qwen2.5-0.5B-Instruct	base	0.000	0.000	0.408
google/flan-t5-small	few_shot	0.000	0.000	0.278
google/flan-t5-small	estruturado	0.000	0.000	0.270
google/flan-t5-small	base	0.000	0.000	0.266


Pathbit Academy AI · dados preservados em data/ · recorte didático, não SLA

Leitura do benchmark multi-modelo com score total e delta sobre a baseline.

PRÓXIMO PASSO CERTO

Prompt ainda paga a conta, mas só até certo ponto

Se o problema é formato, instrução e consistência mínima, ainda há ganho barato na mesa. Quando o gargalo vira contexto atualizado ou comportamento especializado e persistente, aí a próxima conversa deixa de ser prompt e passa a ser RAG ou fine-tuning.



Artigo completo + código para rodar localmente

No repositório, este módulo entrega artigo aprofundado, notebook, benchmark local, CSVs detalhados e leitura por delta contra baseline.

- Artigo com análise completa do experimento
- Notebook para inspecionar ranking e gráficos
- Runner local com artefatos auditáveis

github.com/pathbit/pathbit-academy-ai

REPOSITÓRIO OFICIAL

github.com/pathbit/pathbit-academy-ai

Código 100% aberto, sem chave de API e pronto para execução local.

Acessar Laboratório Completo →

O Erro que Quebra a Confiança

Instrução vaga vs. Contrato de saída estruturado em operações com LLM

INSTÁVEL Sem Método (Instrução Vaga)

Quando o formato de resposta fica implícito, o modelo varia arbitrariamente o tom e a estrutura.

```
prompt_vago.txt
```

"Resuma e chame: Cliente irritado com atraso na entrega."

SAÍDAS IMPREVISÍVEIS EM PRODUÇÃO:

1. Texto Prolixo sem Foco
"O cliente expressou desconforto com a data prevista do frete e solicita resolução com certa prioridade..."

2. Bullet Points Aleatórios
• Motivo: pedido atrasado
• Impacto: alto
• Observação: verificar se tem estoque."

3. Desculpas do Modelo
"Como um modelo de inteligência artificial, sinto muito pelo transtorno do usuário..."

❌ Inviável para ingestão por APIs, bancos de dados ou gerêncs automatizadas

DETERMINÍSTICO Com Método (Contrato de Saída)

O contrato especifica campos obrigatórios, vocabulário fechado e formato padronizado.

```
prompt_estruturado.txt
```

"Você é analista de atendimento Pathbit. Responda EXATAMENTE com 3 linhas: resumo: <uma frase> prioridade: <alta/medial/baixa> proxima_acao: <uma frase objetiva> Mensagem: Cliente irritado com atraso na entrega."

SAÍDA 100% VALIDÁVEL & INTEGRÁVEL:

```
resposta_valida.json
```

```
{  "resumo": "Cliente reclama de atraso fora do prazo contratual",  "prioridade": "ALTA",  "proxima_acao": "Abrir ticket técnico N2 e acionar transportadora em 1h"}
```

✓ Validação instantânea via Regex / Pydantic • Roteamento automatizado sem intervenção manual

Score Total por Estratégia e por Modelo

Laboratório multi-modelo: medindo o impacto das estratégias de prompt em modelos open-source

Performance Relativa (Score Total 0 a 1.0)

Qwen 2.5 0.5B Instruct | Google FLAN-T5 Small

Estratégia	Qwen 2.5 0.5B Instruct	Google FLAN-T5 Small
few_shot (Exemplo Orientador)	0.741	0.278
estruturado (Contrato Rígido)	0.728	0.270
checklist (Raciocínio Operacional)	0.605	0.460 (Melhor FLAN)
base (Instrução Livre - Linha de Base)	0.411	0.260

INSIGHTS | Leitura Executiva

Qwen 0.5B responde a contratos
Stou de 0.411 para 0.741 (+80.2% de ganho). Exemplos few-shot ancoraram estrutura e prioridade sem perda de semântica.

FLAN-T5 prefere checklist
Obteve 0.460 com checklist (+72.6% vs base), mas falhou em seguir contratos JSON-chaves estritas devido ao teto do modelo open-source.

Princípio da Engenharia
O ganho não pertence apenas ao prompt nem apenas ao modelo: ele emerge da compatibilidade entre o desenho de instrução e a capacidade da arquitetura.

A Escada de Evolução Técnica

Critérios arquiteturais para saber quando evoluir de Prompt para RAG ou Fine-Tuning

CUSTO MÍNIMO • ITERAÇÃO EM MINUTOS → Complexidade, Latência e Custo Operacional Aumentam → ESPECIALIZAÇÃO MÁXIMA EM ESCALA

PASSO 1 - BASE

Prompt Engineering

Contratos de saída, parâmetros, heurísticas e few-shot. Resolve formato, concisão e alinhamento básico sem infraestrutura extra.

Custo: Praticamente zero | Deploy: Instantâneo

PASSO 2 - CONTEXTO

RAG Corporativo

Vector databases e embeddings para injetar dados proprietários dinamicos. Quando o modelo precisa de fatos atualizados que ele desconhece.

Foco: Conhecimento dinâmico e citação factual

PASSO 3 - ESTILO

Fine-Tuning (LoRA)

Treinamento supervisionado de pesos para incorporar jargão, regras estritas de raciocínio ou reduzir tokens de prompt em altíssimo volume de requisições.

Foco: Mudança comportamental precisa

PASSO 4 - ESCALA

Arquitetura Híbrida

Fusão de modelo ajustado com pipeline de RAG, guardrails sistêmicos e orquestração de ferramentas. Solução madura para sistemas críticos de missão corporativa.

Foco: Autonomia resiliente e observabilidade total