Série 0005 · Prompt Engineering

O prompt "melhor" não existe sem benchmark

Quando você compara estratégia e modelo ao mesmo tempo, prompt engineering deixa de ser opinião. O artigo mostra como medir ganho real antes de subir custo ou escalar stack.

Leitura completa no artigo + notebook + CSVs

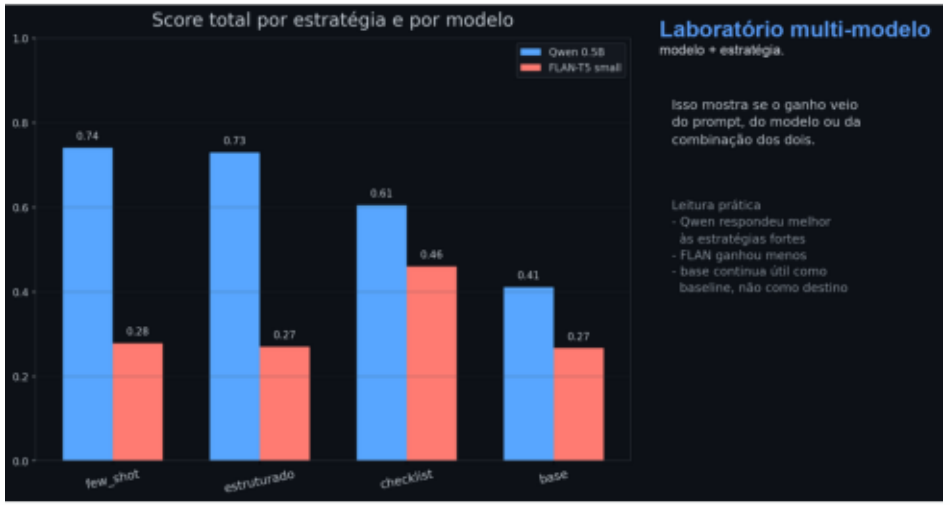

Benchmark comparando a matriz completa de estratégia e modelo.

O problema operacional

Resposta plausível ainda pode quebrar a operação

Prompt genérico costuma convencer na leitura rápida. Quando a saída precisa virar interface de sistema, ele falha justamente onde o time depende de previsibilidade: resumo estável, prioridade confiável e próxima ação objetiva.

Resposta plausível ainda pode quebrar a operação quando não existe contrato de saída.

Entender a mensagem não basta.

O laboratório separa estratégia de capacidade do modelo

O runner cruza `Qwen/Qwen2.5-0.5B-Instruct` e `google/flan-t5-small` com quatro estratégias: `base`, `estruturado`, `few_shot` e `checklist`.

Isso permite responder de onde veio o ganho: do contrato de saída, do exemplo orientador, do checklist operacional ou do teto do próprio modelo.

Framework em quatro camadas para separar instrução, formato e validação.

O primeiro salto real

Contrato de saída continua sendo o divisor de águas

O primeiro avanço não é escrever um prompt mais bonito. É exigir formato estável, com campos nomeados e estrutura mínima validável para o restante do sistema.

Linguagem natural vira interface de sistema quando o formato deixa de ser implícito.

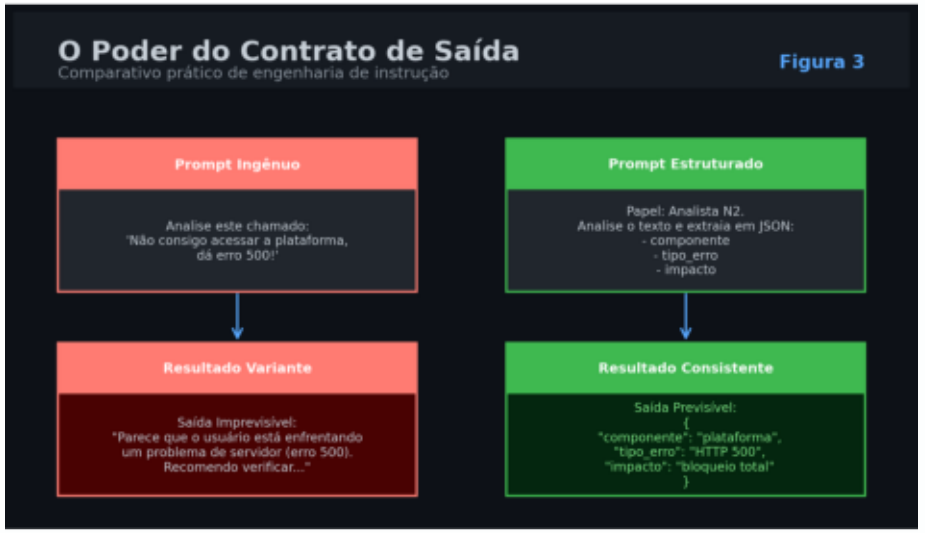

Comparativo entre instrução vaga e prompt com saída estruturada.

Medição séria

Benchmark bom mede forma e significado ao mesmo tempo

O score final combina estrutura, keywords obrigatórias, acerto de prioridade e similaridade semântica. Isso evita duas ilusões comuns: texto bonito sem utilidade operacional, ou formato rígido com resposta semanticamente fraca.

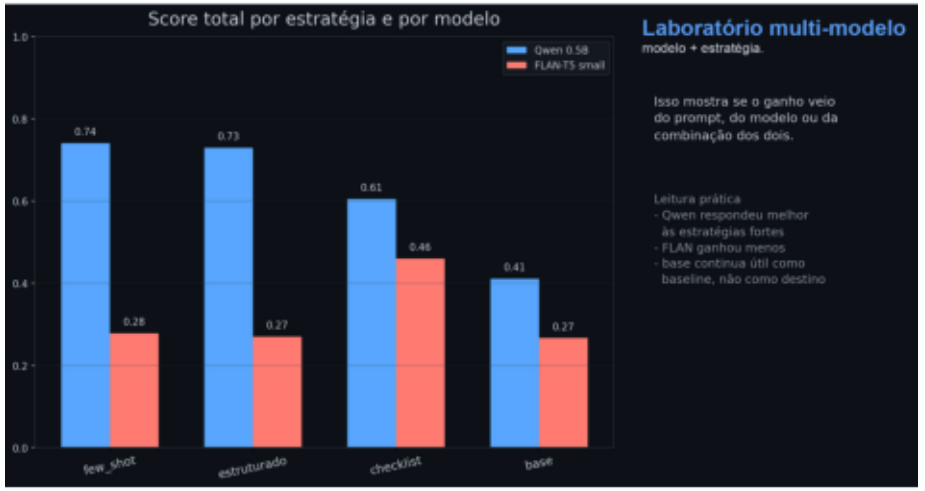

A matriz inteira roda no mesmo dataset e é julgada pelos mesmos critérios.

Resultado observado

O ganho muda com o modelo, não só com o prompt

Qwen: `few_shot` 0.741 vs `base` 0.411, ganho de +80.2%.
FLAN: `checklist` 0.460 vs `base` 0.266, ganho de +72.6%.

A leitura correta é simples: o mesmo prompt não rende igual em todo modelo.

Leitura do benchmark multi-modelo com score total e delta sobre a baseline.

Próximo passo certo

Prompt ainda paga a conta, mas só até certo ponto

Se o problema é formato, instrução e consistência mínima, ainda há ganho barato na mesa. Quando o gargalo vira contexto atualizado ou comportamento especializado e persistente, aí a próxima conversa deixa de ser prompt e passa a ser RAG ou fine-tuning.

Escada de evolução técnica entre prompt engineering, RAG, fine-tuning e híbrido.

O que este módulo entrega

Artigo completo + código para rodar localmente

No repositório, este módulo entrega artigo aprofundado, notebook, benchmark local, CSVs detalhados e leitura por delta contra baseline.

- Artigo com análise completa do experimento
- Notebook para inspecionar ranking e gráficos
- Runner local com artefatos auditáveis

Artigo completo + codigo no repositorio