

Melhor score não basta para liberar deploy

Este módulo transforma LLM Evals em critério de release. Em vez de comparar respostas soltas, a esteira escolhe entre candidatos completos de inferência e reprova mudanças que abrem risco onde mais importa.

- Leitura completa no artigo + notebook + CSVs no repositório



O DADO QUE MUDA A CONVERSA

Sem criticidade, a média engana

O dataset não tem só pergunta e resposta ideal. Ele carrega contexto, palavras críticas, categoria e criticidade para que erro operacional não pese igual a detalhe cosmético.

Um caso crítico ruim vale mais do que um caso trivial bonito.

ARTIGO 0006 • LLM EVALS E REGRESSÃO

Figura 2

Dataset de Avaliação Estruturado

A base de testes carrega contexto factual, palavras-chave mandatórias e nível de criticidade

PERGUNTA DO USUÁRIO	CONTEXTO FORNECIDO (FONTE FACTUAL)	GABARITO (GOLD STANDARD)	CATEGORIA	CRITICIDADE
Qual é o prazo de devolução?	"Política permite estorno em até 30 dias corridos para produto sem uso..."	"30 dias corridos para produtos sem uso e embalagem preservada."	POLÍTICA	ALTA (1.5X)
Como emitir segunda via da fatura?	"Acesse o portal do cliente, abra a aba Financeiro e clique em Segunda Via."	"Portal do cliente > Financeiro > Segunda Via."	FINANCEIRO	ALTA (1.5X)
Posso cancelar sem multa?	"Cancelamento sem multa vale por até 7 dias corridos após a contratação."	"Até 7 dias corridos. Após o prazo, aplica-se a multa contratual."	CONTRATO	ALTA (1.5X)
Erro 500 no aplicativo móvel	"Falhas técnicas persistentes devem abrir chamado com prioridade alta."	"Abrir ticket técnico de suporte com prioridade alta em 1h."	SUPORTE	MÉDIA (1.0X)
Vocês têm plano corporativo?	"Planos empresariais contam com SLA dedicado e gestor de conta."	"Sim, planos corporativos têm SLA dedicado e atendimento customizado."	COMERCIAL	BAIXA (0.8X)
Governança de Dados: O dataset classifica impacto por domínio e criticidade. Isso impede que perguntas fáceis mas irrelevantes mascarem falhas em processos vitais.				data/eval_dataset.csv

Pathbit Academy AI • Engenharia de IA para Produção

Figura 2: Estrutura do dataset de homologação com gabarito ideal e ponderação de risco de negócio

Dataset com contexto, gabarito, categoria e criticidade por caso.

COMO O SCORE É CALCULADO

O score técnico mede aderência antes de ponderar risco

Cada resposta é julgada por similaridade semântica, `keyword_recall` e `faithfulness` ao contexto. Só depois disso a criticidade entra como peso e altera o ranking quando o caso é mais sensível.



O GATE DE RELEASE

Release gate olha ranking e regressão ao mesmo tempo

A decisão final não depende só do campeão da média. O runner calcula delta contra a baseline e procura regressões críticas antes de aprovar a mudança.

Melhor candidato: `flan_estruturado` com 1.357.
Gate corrigido: aprovado para FLAN; as regressões registradas pertencem ao Qwen estruturado.

Gate de release: compare o candidato escolhido

0,05 é um limiar em pontos de score ponderado, não pontos percentuais de acurácia.

Ranking preservado

candidate	score_final	score_ponderado
flan_estruturado	0.905	1.357
qwen_estruturado	0.624	0.936
qwen_generico	0.500	0.750

Regressões históricas

1 registros. O gate corrigido considera somente regressões críticas do vencedor; relatórios antigos não foram alterados.

Limite

Faithfulness neste runner é sobreposição de tokens, não prova de verdade. Acrescente pisos absolutos e casos adversos.

Pathbit Academy AI · dados preservados em data/ · recorte didático, não SLA

Fluxo do gate combinando score ponderado e regressões críticas.

O PONTO DE MATURIDADE

O melhor resultado agregado não liberou produção

A baseline preservada é 0,750 e o vencedor 1,357: ganho de 0,607 pontos. O gate anterior misturava candidatos; agora verifica apenas regressões críticas do escolhido. Relatórios históricos em data/ não foram alterados.

Leaderboard bonito perde para política de release defensável.



EVIDÊNCIA SUFICIENTE

Evals bom deixa rastro suficiente para revisão

A esteira gera `candidate_summary.csv`, `regressoes_detectadas.csv`, recortes por categoria, casos críticos e um relatório textual para explicar por que o deploy foi aprovado ou barrado.



O QUE MUDA PARA O TIME

Comparar candidatos completos muda a discussão do time

Aqui o debate sai de "resposta A vs resposta B" e vira "qual combinação de modelo e prompt melhora o sistema sem esconder regressão operacional".

Evals deixa de ser vitrine de qualidade e vira governança de mudança.

Dataset de Avaliação Estruturado

A base de testes carrega contexto factual, palavras-chave mandatórias e nível de criticidade

PERGUNTA DO USUÁRIO	CONTEXTO FORNECIDO (FONTE FACTUAL)	GABARITO (GOLD STANDARD)	CATEGORIA	CRITICIDADE
Qual é o prazo de devolução?	"Política permite estorno em até 30 dias corridos para produto sem uso..."	"30 dias corridos para produtos sem uso e embalagem preservada."	POLÍTICA	ALTA (1.5X)
Como emitir segunda via da fatura?	"Acesse o portal do cliente, abra a aba Financeiro e clique em Segunda Via."	"Portal do cliente > Financeiro > Segunda Via."	FINANCEIRO	ALTA (1.5X)
Posso cancelar sem multa?	"Cancelamento sem multa vale por até 7 dias corridos após a contratação."	"Até 7 dias corridos. Após o prazo, aplica-se a multa contratual."	CONTRATO	ALTA (1.5X)
Erro 500 no aplicativo móvel	"Falhas técnicas persistentes devem abrir chamado com prioridade alta."	"Abrir ticket técnico de suporte com prioridade alta em 1h."	SUPORTE	MÉDIA (1.0X)
Vocês têm plano corporativo?	"Planos empresariais contam com SLA dedicado e gestor de conta."	"Sim, planos corporativos têm SLA dedicado e atendimento customizado."	COMERCIAL	BAIXA (0.8X)
Governança de Dados: O dataset classifica impacto por domínio e criticidade. Isso impede que perguntas fáceis mas irrelevantes mascarem falhas em processos vitais.				data/eval_dataset.csv

Avaliação deixa de ser comparação rasa e vira governança de mudança.

Artigo completo + esteira pronta para rodar

O módulo entrega runner local, notebook, ranking por candidato, análise crítica e gate final documentado para discutir promoção de release com evidência.

- Artigo com leitura técnica do ranking
- Notebook e CSVs para revisão detalhada
- Harness de release com baseline e regressão

github.com/pathbit/pathbit-academy-ai

REPOSITÓRIO OFICIAL

github.com/pathbit/pathbit-academy-ai

Código 100% aberto, sem chave de API e pronto para execução local.

Acessar Laboratório Completo →

Ranking Ponderado e Decisão de Release

Por que o candidato com maior score global ainda pode ser reprovado para produção

HARNESS DE EVALS

Ranking Ponderado de Candidatos

1º flan_estruturado (google/flan-t5-small)

1.357 score ponderado

1.357

2º qwen_generico (BASELINE) (Qwen 0.5B)

0.932 score ponderado

0.932

3º qwen_estruturado (Qwen 0.5B)

0.930 score ponderado

0.930

Ponderação por Criticidade: Alta (1.5x) • Média (1.0x) • Baixa (0.5x)

Gate de Release CI/CD

REPROVADO

2 Regressões Críticas Detectadas

O candidato qwen_estruturado apresentou piora severa de desempenho nos cenários contratuais mais sensíveis da empresa.

Caso 1: Como emitir segunda via?
Nota contra baseline: -0.200 pontos

Caso 2: Posso cancelar sem multa?
Nota contra baseline: -0.200 pontos

Regra Inegociável: Ganho médio não autoriza regressão em alta criticidade

Dataset de Avaliação Estruturado

A base de testes carrega contexto factual, palavras-chave mandatórias e nível de criticidade

PERGUNTA DO USUÁRIO	CONTEXTO FORNECIDO (PONTE FACTUAL)	GABARITO (GOLD STANDARD)	CATEGORIA	CRITICIDADE
Qual é o prazo de devolução?	"Política permite estorno em até 30 dias corridos para produto sem uso..."	"30 dias corridos para produtos sem uso e embalagem preservada."	POLÍTICA	ALTA (1.5x)
Como emitir segunda via da fatura?	"Acesse o portal do cliente, abra a aba Financeiro e clique em Segunda Via."	"Portal do cliente > Financeiro > Segunda Via."	FINANCEIRO	ALTA (1.5x)
Posso cancelar sem multa?	"Cancelamento sem multa vale por até 7 dias corridos após a contratação."	"Até 7 dias corridos. Após o prazo, aplica-se a multa contratual."	CONTRATO	ALTA (1.5x)
Erro 500 no aplicativo móvel	"Falhas técnicas persistentes devem abrir chamado com prioridade alta."	"Abrir ticket técnico de suporte com prioridade alta em 1h."	SUPORTE	MÉDIA (1.0x)
Vocês têm plano corporativo?	"Planos empresariais contam com SLA dedicado e gestor de conta."	"Sim, planos corporativos têm SLA dedicado e atendimento customizado."	COMERCIAL	BAIXA (0.5x)

Governança de Dados: O dataset classifica impacto por domínio e criticidade. Isso impede que perguntas fáceis mas irrelevantes mascarem falhas em processos vitais.

data/eval_dataset.csv

Gate de release: compare o candidato escolhido

0,05 é um limiar em pontos de score ponderado, não pontos percentuais de acurácia.

Ranking preservado

candidate	score_final	score_ponderado
flan_estruturado	0.905	1.357
qwen_estruturado	0.624	0.936
qwen_generico	0.500	0.750

Regressões históricas

1 registros. O gate corrigido considera somente regressões críticas do vencedor; relatórios antigos não foram alterados.

Limite

Faithfulness neste runner é sobreposição de tokens, não prova de verdade. Acrescente pisos absolutos e casos adversos.

Pathbit Academy AI · dados preservados em data / recorte didático, não SLA

8 / 8

github.com/pathbit/pathbit-academy-ai

0006_llm_evals_regressao