Série 0006 · LLM Evals

Melhor score não basta para liberar deploy

Este módulo transforma LLM Evals em critério de release. Em vez de comparar respostas soltas, a esteira escolhe entre candidatos completos de inferência e reprova mudanças que abrem risco onde mais importa.

Leitura completa no artigo + notebook + CSVs

Ranking ponderado de candidatos com decisão final de release.

O dado que muda a conversa

Sem criticidade, a média engana

O dataset não tem só pergunta e resposta ideal. Ele carrega contexto, palavras críticas, categoria e criticidade para que erro operacional não pese igual a detalhe cosmético.

Um caso crítico ruim vale mais
do que um caso trivial bonito.

Dataset de avaliação com contexto e criticidade

pergunta	contexto	gold	categoria	criticidade
Qual e o prazo de devolucao?	Politica permite estorno em 30 dias corridos...	30 dias corridos...	politica	alta
Como emitir segunda via?	Acesse o portal, Financeiro, Segunda Via...	Portal > Financeiro > Segunda Via	financeiro	alta
Erro 500 no app	Falhas tecnicas devem abrir ticket alta...	Abrir ticket de suporte com prioridade alta	suporte	media

O dataset agora classifica impacto por categoria e criticidade. Isso muda a maturidade do gate.

Dataset com contexto, gabarito, categoria e criticidade por caso.

Como o score é calculado

O score técnico mede aderência antes de ponderar risco

Cada resposta é julgada por similaridade semântica, `keyword_recall` e `faithfulness` ao contexto. Só depois disso a criticidade entra como peso e altera o ranking quando o caso é mais sensível.

Scorecard da avaliação separando dimensões técnicas antes do peso de risco.

Release gate olha ranking e regressão ao mesmo tempo

A decisão final não depende só do campeão da média. O runner calcula delta contra a baseline e procura regressões críticas antes de aprovar a mudança.

Melhor candidato: `flan_estruturado` com 1.357.
Gate atual: reprovado por 2 regressões críticas.

Fluxo do gate combinando score ponderado e regressões críticas.

O ponto de maturidade

O melhor resultado agregado não liberou produção

A baseline ponderada ficou em `0.932` e o melhor candidato abriu ganho de `0.425`. Mesmo assim, o release foi bloqueado porque o conjunto comparado criou risco em casos críticos.

Leaderboard bonito perde para política de release defensável.

O score mais alto não virou deploy automático na esteira atual.

Evidência suficiente

Evals bom deixa rastro suficiente para revisão

A esteira gera `candidate_summary.csv`, `regressoes_detectadas.csv`, recortes por categoria, casos críticos e um relatório textual para explicar por que o deploy foi aprovado ou barrado.

Artefatos produzidos pela esteira para leitura agregada, por categoria e por caso.

O que muda para o time

Comparar candidatos completos muda a discussão do time

Aqui o debate sai de "resposta A vs resposta B" e vira "qual combinação de modelo e prompt melhora o sistema sem esconder regressão operacional".

Evals deixa de ser vitrine de qualidade e vira governança de mudança.

Avaliação deixa de ser comparação rasa e vira governança de mudança.

O que este módulo entrega

Artigo completo + esteira pronta para rodar

O módulo entrega runner local, notebook, ranking por candidato, análise crítica e gate final documentado para discutir promoção de release com evidência.

- Artigo com leitura técnica do ranking
- Notebook e CSVs para revisão detalhada
- Harness de release com baseline e regressão

Artigo completo + codigo no repositorio