


Stack de IA sem nuvem, sem chave e sem custo por token

Este módulo prova, com números medidos na própria máquina, que modelos pequenos em Docker atendem roteamento, extração e retrieval sem nenhuma chamada externa.

- Leitura completa no artigo + notebook + CSVs no repositório




POR QUE LOCAL

Local não é só economizar


A latência de rede vira loopback, o custo por token vira memória da máquina, o dado nunca sai do ambiente e a versão do modelo fica congelada no container.

Com modelo local, o benchmark compara alvos fixos.
Com API de nuvem, o alvo se move toda semana.



Três blocos resolvem o infraestrutura

Ollama em container, modelos abertos em volume persistente e um cliente HTTP em Python padrão. Sem SDK, sem conta, sem cartão.



MEDIÇÃO HONESTA

A latência que a nuvem esconde, aqui fica decomposta

Streaming token a token expõe o tempo até o primeiro token, a geração em si e a carga do modelo. O CSV registra cada linha para responder por que uma resposta demorou.

Sem decomposição de latência, todo problema de performance vira opinião.



BENCHMARK MEDIDO

Modelo escolhe-se por função, não por fama

O 0.5B tem a maior vazão e planner 100% com JSON forçado. O llama3.2:1b tem o menor TTFT e devolveu JSON vazio nas 5 tentativas.

Decodificação estrangida garante sintaxe, não conteúdo.



format: "json" tira o parsing da sorte

O planner do artigo 0007 dependia de JSON utilizável. O Ollama restringe a decodificação, e o laboratório mede quantas tentativas produzem JSON válido e tool correta.



MESMA INSTÂNCIA, MAIS FUNÇÕES

Embeddings locais fecham o stack

O mesmo servidor entrega embeddings para o retrieval top-1. Um container cobre o que os artigos 0002, 0003 e 0007 usaram, sem chamada externa.

Quando o dado não sai do ambiente, piloto sensível destrava na hora.



Artigo completo + laboratório local de benchmarks

O repositório entrega runner, notebook, CSVs e relatório para provar o stack na sua própria máquina.

- Benchmark de chat, JSON e embeddings em um comando
- Evidência em CSV, gráfico e relatório markdown

github.com/pathbit/pathbit-academy-ai

REPOSITÓRIO OFICIAL

github.com/pathbit/pathbit-academy-ai

Código 100% aberto, sem chave de API e pronto para execução local.

Acessar Laboratório Completo →

Anatomia de uma Chamada Medida

Streaming token a token decompõe a latência que a nuvem costuma entregar embalada

REQUEST
POST /api/chat

prompt enviado

TTFT em primeiro chunk

done

TTFT_MS
1º token

ttft_ms

A métrica que define a sensação de velocidade de quem usa

EVAL_COUNT
tokens gerados

eval_count

Contados no último chunk, sem estimativa

EVAL_DURATION
tokens/s

eval_duration

Vazão real do seu hardware, chamada a chamada

TOTAL_MS
latência total

total_ms

Do request à última linha do stream

Por que decompor: quando alguém pergunta "por que a resposta demora?", o CSV responde com carga de modelo, TTFT e geração separados — em vez de uma latência única e opaca.

Benchmark Medido na Própria Máquina

Três modelos pequenos, mesmos prompts, mesma máquina — CPU, Ollama em Docker

qwen2.5-0.5b

200 000 tokens, 1000 prompts

70,8 tokens/s

TTFT médio: 559 ms

Latência total média: 6,33 s

JSON 100% TOOL 100%

llama3.2-1b

1,2 000 tokens, 1000 prompts

31,2 tokens/s

TTFT médio: 258 ms

Latência total média: 6,33 s

JSON 0% TOOL 0%

qwen2.5-1.5b

200 000 tokens, 1000 prompts

18,4 tokens/s

TTFT médio: 1,022 ms

Latência total média: 6,33 s

JSON 100% TOOL 100%

Leitura honesta: médias incluem o resíduo de carga da primeira chamada de cada bloco. O llama3.2-1b com format: "json" devolveu objeto vazio nas 5 tentativas — decodificação constrangida garante sintaxe, não conteúdo. Artefatos completos em data/benchmark_resumo.csv.

Quando Rodar Local — e Quando Não Rodar

A decisão combina sensibilidade do dado com capacidade exigida do modelo

LOCAL — OLLAMA

Dado sensível, tarefa de roteamento, extração ou RAG

Planner de agente, classificação de intenção, retrieval semântico e resumo curto. O dado nunca sai do ambiente e o custo por token é zero.

HÍBRIDO

Dado sensível, raciocínio de longo alcance

Máscara e roteamento local primeiro; só o necessário segue para modelo de fronteira, em região controlada e com contrato de dados.

LOCAL OU NUVEM

Dado público, tarefa simples ou prototipagem

Prova de conceito, demo em sala e desenvolvimento não precisam da nuvem. Rodar local elimina chave e custo do caminho crítico do agendizado.

NUVEM DE FRONTEIRA

Dado público, capacidade de fronteira exigida

Quanto a qualidade do raciocínio é o produto e o volume justifica, modelos de 0.5B a 1.5B não competem aqui, e fingi que competem é desonestidade técnica.