


Stack de IA sem nuvem, sem chave e sem custo por token

Este módulo prova, com números medidos na própria máquina, que modelos pequenos em Docker atendem roteamento, extração e retrieval sem nenhuma chamada externa.

- Leitura completa no artigo + notebook + CSVs no repositório




POR QUE LOCAL

Local não é só economizar


A latência de rede vira loopback, o custo por token vira memória da máquina, o dado nunca sai do ambiente e a versão do modelo fica congelada no container.

Com modelo local, o benchmark compara alvos fixos.
Com API de nuvem, o alvo se move toda semana.



Três blocos resolvem o infraestrutura

Ollama em container, modelos abertos em volume persistente e um cliente HTTP em Python padrão. Sem SDK, sem conta, sem cartão.



MEDIÇÃO HONESTA

A latência que a nuvem esconde, aqui fica decomposta

Streaming token a token expõe o tempo até o primeiro token, a geração em si e a carga do modelo. O CSV registra cada linha para responder por que uma resposta demorou.

Sem decomposição de latência, todo problema de performance vira opinião.



BENCHMARK MEDIDO

Modelo escolhe-se por função, não por fama

O 0.5B tem a maior vazão; os Qwen acertaram 5/5 no teste de planner. O Llama teve menor TTFT e 0/5 no validador do payload. Recorte pequeno, não confiabilidade geral.

Decodificação estrangida garante sintaxe, não conteúdo.

Ollama: tempos e vazão observados

Fonte: benchmark_resumo.csv. Respostas têm comprimentos diferentes; tamanho em disco não é RAM.

Resumo medido

modelo	ttft_medio_ms	total_medio_ms	tokens_por_segundo	tokens_gerados_medios	chamadas
qwen2.5:0.5b	62.400	592.700	187.800	73.700	12
qwen2.5:1.5b	81.300	320.000	106.100	21.200	12
llama3.2:1b	47.500	436.100	89.000	33.300	12

Limite

Sem cobrança de API por token; energia, hardware e operação continuam tendo custo.

Pathbit Academy AI · dados preservados em data/ · recorte didático, não SLA

Comparativo real de três modelos pequenos em CPU: vazão, TTFT, JSON e tool.

format: "json" tira o parsing da sorte

O planner do artigo 0007 dependia de JSON utilizável. O Ollama restringe a decodificação, e o laboratório mede quantas tentativas produzem JSON válido e tool correta.

Ollama: tempos e vazão observados

Fonte: benchmark_resumo.csv. Respostas têm comprimentos diferentes; tamanho em disco não é RAM.

Resumo medido

modelo	ttft_medio_ms	total_medio_ms	tokens_por_segundo	tokens_gerados_medios	chamadas
qwen2.5:0.5b	62.400	592.700	187.800	73.700	12
qwen2.5:1.5b	81.300	320.000	106.100	21.200	12
llama3.2:1b	47.500	436.100	89.000	33.300	12

Limite

Sem cobrança de API por token; energia, hardware e operação continuam tendo custo.

Pathbit Academy AI · dados preservados em data/ · recorte didático, não SLA

JSON forçado no Ollama com taxa de acerto por modelo.

MESMA INSTÂNCIA, MAIS FUNÇÕES

Embeddings locais fecham o stack

O mesmo servidor entrega embeddings para o retrieval top-1. Um container cobre o que os artigos 0002, 0003 e 0007 usaram, sem chamada externa.

Quando o dado não sai do ambiente, piloto sensível destrava na hora.



Artigo completo + laboratório local de benchmarks

O repositório entrega runner, notebook, CSVs e relatório para provar o stack na sua própria máquina.

- Benchmark de chat, JSON e embeddings em um comando
- Evidência em CSV, gráfico e relatório markdown

github.com/pathbit/pathbit-academy-ai

REPOSITÓRIO OFICIAL

github.com/pathbit/pathbit-academy-ai

Código 100% aberto, sem chave de API e pronto para execução local.

Acessar Laboratório Completo →

Anatomia de uma Chamada Medida

Streaming token a token decompõe a latência que a nuvem costuma entregar embalada

O diagrama ilustra o fluxo de uma chamada de API. No topo, uma linha de tempo mostra a sequência de eventos: 'REQUEST POST /api/chat' (ponto azul), 'prompt enviado' (ponto amarelo), 'TTFB em segundos (ms)' (ponto amarelo), e 'done' (ponto verde). Abaixo, quatro cartões representam as métricas: 'TTFB_MS 1º token' (A métrica que define a sensação de velocidade de quem usa), 'EVAL_COUNT tokens gerados' (Contados no último chunk, sem estimativa), 'EVAL_DURATION tokens/s' (Vazão real do seu hardware, chamada a chamada), e 'TOTAL_MS latência total' (Do request à última linha do stream).

Por que decompor: quando alguém pergunta "por que a resposta demora?", o CSV responde com carga de modelo, TTFB e geração separados — em vez de uma latência única e opaca.

Ollama: tempos e vazão observados

Fonte: benchmark_resumo.csv. Respostas têm comprimentos diferentes; tamanho em disco não é RAM.

Resumo medido

modelo	tftf_medio_ms	total_medio_ms	tokens_por_segundo	tokens_gerados_medios	chamadas
qwen2.5:0.5b	62.400	592.700	187.800	73.700	12
qwen2.5:1.5b	81.300	320.000	106.100	21.200	12
llama3.2:1b	47.500	436.100	89.000	33.300	12

Limite

Sem cobrança de API por token; energia, hardware e operação continuam tendo custo.

Pathbit Academy AI - dados preservados em data/ - recorte didático, não SLA

Quando Rodar Local — e Quando Não Rodar

A decisão combina sensibilidade do dado com capacidade exigida do modelo

O diagrama apresenta quatro níveis de sensibilidade do dado, cada um com uma descrição de quando rodar local ou na nuvem. O nível 'LOCAL - OLLAMA' é para dados sensíveis com tarefas de roteamento, extração ou RAG. O nível 'HÍBRIDO' é para dados sensíveis com raciocínio de longo alcance. O nível 'LOCAL OU NUVEM' é para dados públicos com tarefas simples ou prototipagem. O nível 'NUVEM DE FRONTEIRA' é para dados públicos com capacidade de fronteira exigida.