


Saída Estruturada com LLMs: Do Prompt ao Schema Validado

Este módulo prova, com dados medidos em modelos locais, como distinguir parse, schema e decisão correta. O consumidor continua validando timeout, truncamento e contrato.

- Leitura completa no artigo + notebook + CSVs no repositório




O PROBLEMA DA FRAGILIDADE

Prompt otimista não é contrato de engenharia

Pedir JSON no texto livre resulta em markdown fences, preâmbulos e chaves alucinadas. O `json.loads` quebra e derruba o pipeline de produção.


Em produção corporativa, confiar em prompt livre para gerar JSON é assumir débito técnico no primeiro deploy.



Grammar-Guided Sampling: máscara de logits em tempo real

O runtime usa o subconjunto de schema suportado para guiar a gramática. JSON aninhado não se reduz a uma FSM simples; valide a saída no consumidor.

O modelo não tem como errar a sintaxe: a máscara física impede qualquer token ilegal.



EVIDÊNCIA EMPÍRICA

Dados preservados: forma válida não significa decisão correta

Livre: 0% parse. JSON: 88,9% parse e 0% schema. Schema: 100% conformidade e 44,4% acerto semântico. São 18 linhas consolidadas por modo, com até um retry.

Schema estrito não engessa o modelo: ele concentra a probabilidade na semântica correta.

Sintaxe, schema e acerto de negócio

18 linhas consolidadas por modo; o tempo pode incluir uma tentativa extra.

Resumo preservado

modo	parse_ok_pct	schema_ok_pct	semantico_ok_pct	total_medio_ms
json	88.900	0.000	0.000	1158.300
livre	0.000	0.000	0.000	3007.700
schema	100.000	100.000	44.400	400.500

Interpretação

100% de conformidade no recorte não significa decisão correta: schema teve 44,4% de acerto semântico.

Pathbit Academy AI · dados preservados em data/ · recorte didático, não SLA

Comparativo medido: conformidade e assertividade nos 3 modos.

O CUSTO DO RETRY

O mito do retry compensatório

Retries aumentam o custo de forma variável. Neste recorte, schema teve média de 400,5 ms e livre 3.007,7 ms; não é medição isolada de overhead nem SLA.

Retries devem tratar regras de negócio semânticas, nunca sintaxe quebrada.

Retry: custo acumulado, não overhead constante

Fonte: structured_resumo.csv; o runner consolida até duas tentativas por tarefa.

Latência consolidada

modo	total_medio_ms	tokens_medios	chamadas
json	1158.300	39.200	18
livre	3007.700	87.200	18
schema	400.500	22.700	18

Política

Retry ocorre após falha de parse/schema. Uma saída semanticamente errada que passa no schema não é corrigida por essa política.

Limite

Compare recuperação, latência e tokens de todas as tentativas. Não afirme que retry sempre dobra o tempo ou que schema tem overhead fixo.

Pathbit Academy AI · dados preservados em data/ · recorte didático, não SLA

Tempos consolidados e custo acumulado de retry.

Contrato desacoplado e tipagem estrita

O contrato em Pydantic/JSON Schema vira especificação única. O backend valida ou rejeita a saída; isso não prova correção semântica ou conformidade regulatória.

A saída estruturada transforma um gerador probabilístico de texto em uma API determinística.



O benchmark local mede embeddings e três rótulos; não executa modelos comerciais de decisão.

Modelos roteamento não generativo: Decisão Direta em ~30 ms

O benchmark local mede embeddings e três rótulos; não executa modelos comerciais de decisão.

A separação moderna: decisões em roteamento não generativo (< 40ms) e redação rica em System 2.

Roteamento sem geração: baseline por embeddings

O nome histórico system_one_comparativo.json foi preservado; não mede Jev, Laya ou Kev.

Métricas observadas

chamadas_avaliables	latencia_media_ms	latencia_p50_ms	latencia_p95_ms	acuracia_pct
6	12.970	13.610	17.220	100.000

Implementação

nomic-embed-text → similaridade de cosseno → maior score entre três rotas. Similaridade/softmax não é confiança calibrada.

Limite

Escolher rótulo não extrai parâmetros nem equivale às tarefas do LLM com schema. Complexidade varia com o texto.

Pathbit Academy AI · dados preservados em data/ · recorte didático, não SLA

Saída Estruturada + Modelos roteamento não generativo

Do prompt otimista à garantia formal via Grammar-Guided Sampling, com benchmarks empíricos em modelos locais.

- 100% de conformidade no recorte, com validação no consumidor
- Desacoplamento com Pydantic e JSON Schema estrito
- Avaliação empírica de decisores roteamento não generativo vs autoregressão

github.com/pathbit/pathbit-academy-ai

REPOSITÓRIO OFICIAL

github.com/pathbit/pathbit-academy-ai

Código 100% aberto, sem chave de API e pronto para execução local.

Acessar Laboratório Completo →

Como Funciona a Decodificação Constrangida

Grammar-Guided Sampling: máscara de logits via Autômato de Estados Finitos (FSM)

PASSO 1 - PREDIÇÃO LLM

Cálculo dos Logits

A cada token gerado, o modelo neural produz uma distribuição de probabilidades não normalizada (logits) sobre todo o vocabulário de ~100.000 tokens.

"tool" [0.8], "response" [0.4], "oi" [0.0], "oi!" [0.2], "oi!!" [0.0]

PASSO 2 - VALIDADOR DE GRAMÁTICA

Máscara de Gramática (BNF / FSM)

O JSON Schema foi compilado em um Autômato de Estados Finitos. O autômato identifica o estado atual (ex: esperando o valor do enum "tool").

Tokens legais recebem `logit * 0.8` → (probabilidades 0). Apenas tokens que preservam o schema são mantidos.

PASSO 3 - TOKEN SELECIONADO

Amostragem Válida

O token amostrado pertence obrigatoriamente à linguagem do schema. A sintaxe e os tipos são mantidos e a estruturação estrutural.

token_selecionado = "tool:portar" status = 100% VÁLIDO

Por que o modelo não fica mais "burro"? A máscara não altera o conhecimento do modelo; ela apenas proíbe que ele gaste probabilidade em formatos inúteis para o código. O modelo é forçado a alocar 100% de sua atenção nos dados reais da resposta.

Sintaxe, schema e acerto de negócio

18 linhas consolidadas por modo; o tempo pode incluir uma tentativa extra.

Resumo preservado

modo	parse_ok_pct	schema_ok_pct	semantic_ok_pct	total_medio_ms
json	88.900	0.000	0.000	1158.300
livre	0.000	0.000	0.000	3007.700
schema	100.000	100.000	44.400	400.500

Interpretação

100% de conformidade no recorte não significa decisão correta: schema teve 44,4% de acerto semântico.

Pathbit Academy AI - dados preservados em data/ - recorte didático, não SLA

Roteamento sem geração: baseline por embeddings

O nome histórico system_one_comparativo.json foi preservado; não mede Jev, Laya ou Kev.

Métricas observadas

chamadas_avaliadas	latencia_medio_ms	latencia_p50_ms	latencia_p95_ms	acuracia_pct
6	12.970	13.610	17.220	100.000

Implementação

nomlc-embed-text → similaridade de cosseno → maior score entre três rotas. Similaridade/softmax não é confiança calibrada.

Limite

Escolher rótulo não extrai parâmetros nem equivale às tarefas do LLM com schema. Complexidade varia com o texto.

Pathbit Academy AI - dados preservados em data/ - recorte didático, não SLA