


Saída Estruturada com LLMs: Do Prompt ao Schema Validado

Este módulo prova, com dados medidos em modelos locais, como sair do prompt ingênuo e garantir 100% de conformidade de schema sem quebra de parse no backend.

- Leitura completa no artigo + notebook + CSVs no repositório




O PROBLEMA DA FRAGILIDADE

Prompt otimista não é contrato de engenharia

Pedir JSON no texto livre resulta em markdown fences, preâmbulos e chaves alucinadas. O `json.loads` quebra e derruba o pipeline de produção.

Em produção corporativa, confiar em prompt livre para gerar JSON é assumir débito técnico no primeiro deploy.



Grammar-Guided Sampling: máscara de logits em tempo real

O schema é compilado em uma máquina de estados finitos. A cada token gerado pelo modelo, tokens inválidos recebem probabilidade zero.

O modelo não tem como errar a sintaxe: a máscara física impede qualquer token ilegal.

Como Funciona a Decodificação Constrangida

Grammar-Guided Sampling: máscara de logits via Autômato de Estados Finitos (FSM)



Logits masking guiado por Autômato de Estados Finitos.

EVIDÊNCIA EMPÍRICA

Números medidos: de 55% a 100% de conformidade

No modo livre, quase 30% das chamadas sequer parseiam. Com `format: <schema>`, a conformidade salta para 100% e a assertividade de negócio atinge o teto.

Schema estrito não engessa o modelo: ele concentra a probabilidade na semântica correta.



O CUSTO DO RETRY

O mito do retry compensatório

Tentar consertar saída livre com novo prompt custa o dobro da latência. A imposição de schema adiciona overhead desprezível e resolve na 1ª tentativa.

Retries devem tratar regras de negócio semânticas, nunca sintaxe quebrada.



Contrato desacoplado e tipagem estrita

O contrato em Pydantic/JSON Schema vira especificação única. O backend deserializa com garantia total e audita cada decisão em CSV/JSONL.

A saída estruturada transforma um gerador probabilístico de texto em uma API determinística.



Modelos System 1: Decisão Direta em ~30 ms

Por que gerar 40 tokens sequenciais se o sistema precisa apenas de uma decisão tipada? Modelos System 1 usam passada única (O(1)) para Choice, Score e Bool com mais de 50x de redução de latência.

A separação moderna: decisões em System 1 (< 40ms) e redação rica em System 2.

