


MCP Local: Model Context Protocol 100% Offline com Ollama

Este módulo conecta o protocolo aberto da Anthropic a um servidor local via stdio e modelos de inferência offline, provando ferramentas governáveis sem rede e sem chaves.

- [Leitura completa no artigo + notebook + CSVs no repositório](#)




POR QUE MCP

O padrão aberto para conectar ferramentas a LLMs

Em vez de criar adaptadores manuais para cada framework, o Model Context Protocol padroniza ferramentas, recursos e prompts sob uma especificação universal.

Com transporte stdio, o protocolo roda inteiramente dentro da máquina: zero portas TCP, zero tráfego externo.



Desacoplamento total entre agente e ferramentas

O agente inicia a sessão e pergunta ao servidor quais tools estão disponíveis via `list_tools()`. As ferramentas entram no prompt do modelo sem código fixo.

Você adiciona ou remove capacidades no servidor MCP sem alterar uma única linha do agente.

Descoberta Dinâmica de Ferramentas (`list_tools`)

O contrato desacoplado: o modelo aprende as ferramentas em tempo de execução

1. DEFINIÇÃO NO SERVIDOR

mcp_server.py

Decorador `@mcp.tool()`

O servidor infere tipos do Python e docstrings para gerar o schema JSON-RPC automaticamente.

```
@mcp.tool() def buscar_politica(topico: str) -> str: """Busca politica interna da empresa (devolucao, cancelamento, segunda_via)""" return POLITICAS.get(topico) @mcp.tool() def criar_ticket(titulo: str, prioridade: str = "media") -> str: """Abre chamado tecnico. Aceita: baixa, media, alta.""" return f"ticket#{id} criado com sucesso"
```

2. DESCOBERTA E INJEÇÃO NO PROMPT

mcp_lab.py

Consulta via `session.list_tools()`

O catálogo descoberto é transformado no prompt do planner sem hardcode de ferramentas no cliente.

Você é o planner do agente. Escolha a tool para a pergunta: Tools disponíveis (descobertas via MCP): - buscar_politica: Busca politica interna da empresa - criar_ticket: Abre chamado tecnico - responder_direto: Use para dúvidas gerais Pergunta: 'quero a segunda via da fatura' Responda um JSON com "tool" e "argumentos".

⚡ **Desacoplamento Total:** Adicione ou remova ferramentas no servidor MCP sem alterar uma única linha do código do agente ou do prompt base. A esteira descobre as capacidades dinamicamente.

`list_tools` descobre ferramentas e schemas em tempo de execução.

Do texto livre à ação real na máquina

A pergunta do usuário é processada pelo Ollama com schema rígido (artigo 0009). O plano resultante dispara a tool correspondente via `session.call_tool()`.

O modelo apenas planeja a intenção; quem toca no dado é a ferramenta inspecionada.



Meça protocolo isolado e chamada completa separadamente

50 chamadas isoladas: p50 0,99 ms, p95 1,53 ms. No ciclo do planner, call_tool teve médias de 4,7 a 7,5 ms; não são a mesma medição nem garantia de menos de 1 ms.

Padronização com MCP não compromete a performance da sua arquitetura agêntica.

MCP: protocolo isolado e ciclo completo

São medições diferentes, não garantia de overhead inferior a 1 ms.

50 chamadas isoladas

chamadas	p50_ms	p95_ms	media_ms
50	0.990	1.530	1.080

Planner e chamada por modelo

modelo	tool_certa_pct	plan_medio_ms	mcp_medio_ms
llama3.2:1b	83.300	2117.600	4.700
qwen2.5:1.5b	50.000	2213.300	6.500
qwen2.5:0.5b	33.300	1764.400	7.500

Segurança

Stdio não é sandbox. Valide argumentos, permissões, timeouts e encerramento de processos.

Pathbit Academy AI · dados preservados em data/ · recorte didático, não SLA

50 chamadas de protocolo: p50 de 0.99 ms vs 1.700 ms do modelo.

Auditoria forense e menor privilégio

Cada decisão agêntica, argumentos validados e tempos de execução são gravados em log estruturado. Em ambientes corporativos, auditoria é pré-requisito de deploy.

Governança transforma autonomia probabilística em sistema confiável para produção.



